

Système Automatisé de Traitement des Marchés Publics

Stratégie d'Apprentissage et d'Optimisation du Pipeline de Classification Documentaire

Document : Rapport Technique d'Architecture &
d'IA

Réalisé par : Achraf

21 juillet 2026

Résumé — Ce document présente la conception technique et la stratégie d'apprentissage du module de classification automatique de documents pour la plateforme **Waraq**. À travers une approche hybride en cascade combinant des règles déterministes, l'extraction de texte natif et l'inférence par un Modèle de Langage (*LLM Qwen 2.5*), le pipeline garantit un traitement hautement performant, évolutif et auto-apprenant via une technique de *Few-Shot Learning* dynamique en temps réel.

1. Contexte et Objectifs du Module de Classification

Dans le cadre de la modernisation et de la dématérialisation du traitement des marchés publics au Maroc, la plateforme **Waraq** est amenée à traiter, analyser et structurer à grande échelle une grande diversité de documents administratifs et techniques.

Les typologies documentaires couvertes incluent notamment :


- **Avis d'Appels d'Offres** (Avis de publication) ;
- **Cahiers des Prescriptions Spéciales (CPS)** ;
- **Règlements de Consultation (RC)** ;
- **Bordereaux des Prix - Détails Estimatifs (BPDE)** ;
- **Actes d'Engagement** et pièces administratives annexes.

L'objectif central de la stratégie mise en œuvre est d'assurer une classification **rapide, ultra-précise et auto-apprenante**. Le système exploite une synergie entre des règles déterministes à latence nulle, une extraction directe de texte natif et une inférence IA basée sur un Modèle de Langage (LLM), tout en intégrant une boucle de rétroaction continue alimentée par les corrections des utilisateurs humains.

2. Architecture Technique du Pipeline Hybride

Le pipeline de traitement s'articule autour d'une **approche en cascade à quatre niveaux**, conçue pour optimiser l'utilisation des ressources informatiques, réduire le temps d'inférence et maximiser la précision globale.

2.1. Représentation Schématique de la Cascade



2.2. Description Détaillée des Niveaux de Traitement

2.2.1. Niveau 1 : Filtrage par Règles Primitives (Déterministe)

Avant de faire appel à des ressources informatiques lourdes (GPU/CPU/OCR), le système applique un ensemble de règles déterministes strictes basées sur les métadonnées primaires du fichier :

- Extensions spécifiques (ex. feuille de calcul `.xlsx`, `.csv` pour les bordereaux de prix).
- Préfixes ou motifs explicites dans le nom du fichier (ex. `CPS_*`, `RC_*`, `AVIS_*`).

Ce niveau permet de résoudre les cas évidents sans coût computationnel ni latence.

2.2.2. Niveau 2 : Extraction de Texte Natif

Afin d'éviter la lourdeur et les imprécisions d'un moteur d'OCR (Reconnaissance Optique de Caractères sur image), le pipeline extrait directement le texte natif encodé de l'ensemble du document PDF. Cette méthode permet de capturer l'intégralité du contenu textuel du document pour une analyse exhaustive.

2.2.3. Niveau 3 : Classification par Inférence LLM (Qwen 2.5 : 7B)

Lorsque les règles primitives ne permettent pas de conclure, le texte extrait est transmis au modèle de langage **Qwen 2.5 (7B)** via l'environnement Ollama. Le modèle renvoie une structure JSON stricte contenant :

- **Type de document** : Catégorie retenue (ex. `CPS`, `RC`, `Avis`).
- **Justification** : Explication en français motivant la décision.
- **Score de confiance** : Valeur normalisée entre 0.0 et 1.0.
- **Mots-clés prédominants** : Termes clés déterminants identifiés.
- **Langue** : Langue détectée du document (Français, Arabe).

2.2.4. Niveau 4 : Analyse Poly-documentaire et Découpage Automatique

Pour les dossiers volumineux regroupant plusieurs sous-documents au sein d'un même fichier PDF (ex. un dossier unique contenant l'Avis + le RC + le CPS), le pipeline procède à une analyse structurelle par blocs de pages, détecte les ruptures de contenu et effectue un découpage physique automatisé.

3. Stratégie d'Apprentissage Continu (*Few-Shot Learning* Dynamique)

Pour permettre à l'IA d'apprendre continuellement de ses erreurs sans passer par des phases de réentraînement lourd **Fine-Tuning**, le système exploite la technique d'**Apprentissage en Contexte (In-Context Learning)**.

Principe de Fonctionnement du Feedback Loop

1. **Validation et Correction Humaine** : Lorsqu'un utilisateur corrige une classification sur la plateforme, le fichier passe au statut **CORRIGE** et conserve son type final validé.
2. **Reconstruction du Contextualiseur** : À chaque nouvelle exécution, le moteur interroge la base de données PostgreSQL pour extraire les corrections historiques.
3. **Extraction des Paires de Contexte** : Extraction des tuples : (*Extrait de texte d'origine* → *Correction validée*).
4. **Injection Dynamique (Prompt Engineering)** : Les erreurs passées sont intégrées sous forme d'exemples (*Few-Shot Examples*) dans la consigne système transmise à Qwen 2.5.

3.1. Avantages de l'Option A (Few-Shot vs Fine-Tuning)

Axe d'évaluation	Apport de l'In-Context Learning
Temps de Prise en Compte	Instantané (dès le document suivant)
Adaptabilité Régionale	Assimilation rapide du jargon administratif marocain
Sécurité du Modèle	Préservation de l'intégrité des poids d'origine
Coût Computationnel	Faible (pas de boucle de rétropropagation/GPU dédiée)

TABLE 1 – Comparatif des bénéfices de l'apprentissage en contexte.

4. Déploiement Hybride et Déport des Calculs (Option B : Cloud / Colab)

Afin de préserver les ressources matérielles de l'environnement local lors des phases intenses de **scraping** et d'entrées/sorties en base de données, l'architecture permet de déporter la charge d'inférence LLM vers une infrastructure distante accélérée par GPU (ex. Google Colab avec NVIDIA T4).

4.1. Architecture de Déport

- **Serveur Local Waraq** : Exécute les tâches d'acquisition (**scraping**), la gestion de la base PostgreSQL, l'extraction textuelle et l'organisation des fichiers.
- **Serveur Distant Dédié** : Héberge le moteur **Ollama** sur GPU et exécute Qwen 2.5.
- **Tunnel Sécurisé (Ngrok)** : Établit une liaison HTTP/HTTPS chiffrée entre le local et l'instance distante.

5. Impact Technique et Bénéfices Métiers

L'implémentation de cette stratégie hybride offre des avantages quantifiables pour l'exploitation quotidienne de la plateforme **Waraq** :

- **Gain de Temps de Traitement** : Traitement de la majorité du flux documentaire en quelques millisecondes grâce aux Niveaux 1 et 2, réservant l'appel IA aux cas complexes.

- **Traçabilité et Auditabilité :** Chaque décision est enregistrée avec sa justification, son score de confiance et ses métadonnées d'exécution.
- **Scalabilité :** L'apprentissage continu par injection de contexte permet une augmentation organique de la précision au fur et à mesure de l'utilisation.